

# 手语数字人项目方案与分工

## 一、项目概述

### 1.1 项目背景

本项目基于 Uni-Sign (ICLR 2025 收录论文)，这是一个统一的大规模手语理解框架，实现从手语视频到文本的翻译。项目代码已包含完整的模型架构、数据处理和实时摄像头推理功能。

### 1.2 核心目标

- 暑期任务：5 名成员各自独立实现三个模型方案
- 结果对比：在同一数据集上对比不同模型的识别效果
- 择优选用：最终选择效果最佳的模型作为项目成果

## 二、团队分工

| 成员         | 负责模型                                                                                                                                                                                                                   | 核心任务                                                                          |
|------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------------------|
| 王静<br>(组长) | <ul style="list-style-type: none"><li>• <a href="#">SignGraph (CVPR 2024)</a> (连续手语识别)</li><li>• <a href="#">TwoStream Network (NeurIPS 2022)</a> (识别+翻译)</li><li>• <a href="#">VSNet (CVPR 2025)</a> (手语识别)</li></ul> | 统筹项目进度；选取高准确率模型 SignGraph、TwoStream 与数字人适配方案 VSNet，搭建基准并组织统一评测                |
| 巴依         | <ul style="list-style-type: none"><li>• <a href="#">Sign2GPT (ICLR 2024)</a> (手语翻译)</li><li>• <a href="#">CVT-SLR (CVPR 2023)</a> (手语识别)</li><li>• <a href="#">KD-MSLRT (AAAI 2025)</a> (连续手语识别)</li></ul>             | 负责 LLM 路线翻译与高精度单流识别模型复现；探索 GPT 风格手语翻译与跨模态对齐方法，与 Uni-Sign 做同代技术路线对比            |
| 陈祉含        | <ul style="list-style-type: none"><li>• <a href="#">GASLT (CVPR 2023)</a> (手语翻译)</li><li>• <a href="#">C2SLR (CVPR 2022)</a> (连续手语识别)</li><li>• <a href="#">SignCLIP (EMNLP 2024)</a> (手语理解)</li></ul>                 | 负责 gloss-free 翻译与稳健识别备选模型复现；提供与 Uni-Sign 同路线的可对比方案，并探索 CLIP 对比学习 zero-shot 能力 |

| 成员  | 负责模型                                                                                                                                                                                                                                              | 核心任务                                                        |
|-----|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------------------|
| 谭燕琪 | <ul style="list-style-type: none"><li>• <a href="#">A Simple Baseline (ECCV 2024)</a> (手语生成(SLP))</li><li>• <a href="#">Sign-IDD (AAAI 2025)</a> (手语生成)</li><li>• <a href="#">SEDS (ACM MM 2024)</a> (手语检索)</li></ul>                             | 负责手语生成(SLP)与检索方向模型复现；为数字人补齐“文本/音频→手语动作”生成能力，并引入自动评估工具       |
| 郑松屹 | <ul style="list-style-type: none"><li>• <a href="#">SOKE (Signs as Tokens) (ICCV 2025)</a> (手语生成)</li><li>• <a href="#">Progressive Transformers (ECCV 2020)</a> (手语生成(SLP))</li><li>• <a href="#">SignAvatar (IEEE FG 2024)</a> (手语生成)</li></ul> | 负责端到端手语生成与经典 SLP 基线复现；探索自回归 token 生成与 3D 动作重建方案，扩展数字人动作生成路径 |

### 三、技术方案

#### 3.1 数据集

统一使用以下数据集进行训练和测试：

- CSL\_Daily：中文日常手语（推荐作为主测试集）
- WLASL：美式手语（辅助测试）
- How2Sign/OpenASL：可选扩展

#### 3.2 各模型方案详解

##### 🔑 方案一：王静（组长）

##### ■ SignGraph（CVPR 2024）

论文：[SignGraph: A Sign Sequence is Worth Graphs of Nodes](#)

代码：<https://github.com/gswycf/SignGraph>

方向：连续手语识别

推荐理由：

从准确率看，SignGraph 是这批候选里非常值得重点考虑的模型。官方仓库给出的结果显示，其在 Phoenix-2014 数据集上测试集 WER 可达到 18.17，在 Phoenix-2014T 上测试集 WER 为 19.44，在不额外引入多模态辅助信息的情况下，已经达到非常强的识别性能。对于连续手语识别任务而言，WER 越低越好，因此该模型在准确率维度上具有明显优势。从方法上看，SignGraph 将手语序列

表示成图结构，通过局部图和时间图建模帧内区域关系与跨帧动态关系，相比传统 CNN 网格建模方式，更贴合手语动作识别的本质需求。这意味着它不仅结果强，而且模型设计本身也有较好的论文阐述价值。从项目适配性看，SignGraph 的一个重要优点是“高准确率且不依赖额外 cue”，这使得后续接入视频识别链路时更直接，不必强绑定复杂的姿态流或额外传感器。若项目把识别准确率作为最重要指标，SignGraph 非常适合作为首选主模型。

#### ■ TwoStream Network (NeurIPS 2022)

论文: [Two-Stream Network for Sign Language Recognition and Translation](#)

代码: <https://github.com/FangyunWei/SLRT>

方向: 识别+翻译

**推荐理由:**

TwoStream Network 是当前手语识别与翻译中兼顾性能和成熟度的代表性模型。官方结果表明，其在 Phoenix-2014 上测试集 WER 为 18.8，在 Phoenix-2014T 上测试集 WER 为 19.3，同时在翻译任务上还可在 Phoenix-2014T 上取得约 29.0 的 BLEU-4，整体表现十分突出。该模型采用 RGB 视频流与人体关键点流双分支联合建模，能够同时捕获外观信息与结构动作信息，因此在准确率上通常优于单纯视频模型。对于本项目而言，这种双流设计也与“视频识别 + 骨骼特征 + 数字人驱动”的整体路线较一致。若单从性能稳定性和公开资料完整度来看，TwoStream 是非常稳妥的高精度方案。它的缺点是推理链路相对更复杂，但如果项目目标强调“结果尽量强”，那么 TwoStream 仍应排在最优先队列。

#### ■ VSNet (CVPR 2025)

论文: VSNet: Focusing on the Linguistic Characteristics of Sign Language

代码: <https://github.com/ZechengLi19/Awesome-Sign-Language>

方向: 手语识别

**推荐理由:**

针对当前手语数字人识别精度不足核心痛点设计，专门建模手语语言学视觉特征，大幅区分外形相似手势，解决现有模型混淆数字、基础词汇手势的问题；轻量化骨架输入方案，依托 MediaPipe 提取人体 / 手部关键点作为唯一输入，和数字人 UE5 管线原生适配，无需额外视频图像预处理；无大规模预训练强制要求，仅依靠 WLASL、NMFs-CSL、SLR500 常规手语数据集即可快速收敛到 SOTA 效果，微调成本低；完整开源训练 + 推理代码，模块解耦，可快速嵌入现有数字人识别链路，支持孤立词、短句两种推理模式，适配数字人词汇交互、

手语教学场景。

### 核心任务：

统筹项目进度；选取高准确率主模型 SignGraph、TwoStream 与数字人适配方案 VSNet，搭建基准并组织统一评测

### 实施计划：

- 配置环境并完成数据预处理
- 复现模型并在 CSL\_Daily / Phoenix-2014(T) 上评估
- 记录 WER / BLEU-4 等指标并与组长基准对比
- 整理复现笔记与可运行代码，合并到主分支

## 🔗 方案二：巴依（成员）

### ■ Sign2GPT（ICLR 2024）

论文：Sign2GPT

代码：<https://github.com/ryanwongsa/Sign2GPT>

方向：手语翻译

### 推荐理由：

把大语言模型用到手语翻译上——这和现有的 Uni-Sign（也是基于 mT5 预训练模型）属于同一代技术路线，但 Sign2GPT 做的是“用 GPT 的方式做翻译”。①用 GPT 风格的 decoder-only LLM 做手语翻译（不是 encoder-decoder）；②两阶段训练：第一阶段在大量无标注数据上预训练视觉编码器，第二阶段在标注数据上微调翻译——这和现有系统实际的生产环境很接近（现有的模型有大量视频但没有文字标注）；③代码极其完整——有 Dockerfile 和环境文件，一键建环境；④支持 CSL-Daily，和现有数据匹配；⑤BLEU 分数在 CSL-Daily 上达到 SOTA。

### ■ CVT-SLR（CVPR 2023）

论文：CVT-SLR: Contrastive Visual-Textual Transformation for Sign Language Recognition with Variational Alignment

代码：<https://github.com/binbinjiang/CVT-SLR>

方向：手语识别

### 推荐理由：

CVT-SLR 是一类高性能单流识别模型，重点利用视觉与文本之间的跨模态对齐来提升识别效果。官方仓库显示，其在 Phoenix-2014 上测试集 WER 可达到 20.06 左右，开发集约为 19.80，在不依赖多流额外输入的条件下，已经优于

不少较早的多模态方法。这类方法的突出优势在于：虽然准确率很强，但整体结构比部分复杂多流模型更“干净”，更适合作为高精度单流代表模型。若希望在论文或材料里体现“不仅考虑双流模型，也对高性能单流方法进行了比较”，CVT-SLR 很适合被列入重点候选。需要注意的是，CVT-SLR 在工程实现上对数据预处理和训练配置较敏感，复现门槛会略高于传统 baseline。但如果把准确率放在第一位，它仍然比很多“好复现但性能一般”的模型更值得进入最终候选名单。

#### ■ KD-MSLRT (AAAI 2025)

论文：KD-MSLRT: Lightweight Sign Language Recognition Model Based on Mediapipe and 3D to 1D Knowledge Distillation

代码：<https://github.com/ZechengLi19/Awesome-Sign-Language>

方向：连续手语识别

#### 推荐理由：

轻量化蒸馏架构，模型体积极小，CPU 端毫秒级实时推理，适配数字人客户端、网页端、UE5 离线实时交互场景，无高算力 GPU 依赖；面向连续长句手语识别，适配直播、对话类手语数字人实时转文字需求，在 CSL-Daily、Phoenix-2014T 主流连续手语数据集 WER 优于传统模型；和 VSNet 共用同一套 MediaPipe 骨骼提取预处理管线，一套代码可自由切换两套识别模型，改造、替换现有识别模块成本极低；内置文本校正分支，识别输出文字自带纠错优化，无需额外搭建后处理翻译模块，直接对接数字人文字展示、语音播报功能。

#### 核心任务：

负责 LLM 路线翻译与高精度单流识别模型复现；探索 GPT 风格手语翻译与跨模态对齐方法，与 Uni-Sign 做同代技术路线对比

#### 实施计划：

- 配置环境并完成数据预处理
- 复现模型并在 CSL\_Daily / Phoenix-2014(T) 上评估
- 记录 WER / BLEU-4 等指标并与组长基准对比
- 整理复现笔记与可运行代码，合并到主分支

#### 🔗 方案三：陈祉含（成员）

#### ■ GASLT (CVPR 2023)

论文：GASLT - Gloss Attention for Gloss-free Sign Language Translation

代码: <https://github.com/YinAoXiong/GASLT>

方向: 手语翻译

**推荐理由:**

走的是手语转文字方向, 可以用来替换或对比现有的 Uni-Sign。①不需要 gloss 标注就能做手语翻译, 和现有的 Uni-Sign 一样都是 gloss-free 路线; ②核心创新是“Gloss Attention”——用注意力机制隐式学出手语的 gloss 级别的语义对齐, 而不是显式依赖 gloss 标注; ③支持 CSL-Daily (中文手语), 和现有数据匹配; ④PyTorch 代码, 有完整的 env.yaml 环境和训练/测试命令。

## ■ C2SLR (CVPR 2022)

论文: C2SLR: Consistency-enhanced Continuous Sign Language Recognition

代码: [https://github.com/2000ZRL/LCSA\\_C2SLR\\_SRM](https://github.com/2000ZRL/LCSA_C2SLR_SRM)

方向: 连续手语识别

**推荐理由:**

C2SLR 是连续手语识别中一条非常稳健的高性能路线。公开结果显示, 其在 Phoenix-2014 上测试集 WER 为 20.4, 在 Phoenix-2014T 上测试集 WER 也达到 20.4, 属于长期被反复引用和比较的强基线。与一些更新更复杂的方法相比, C2SLR 的绝对指标不是最顶尖, 但它的优点在于结果可靠、代码和配置较完整、方法逻辑清晰, 在高精度候选中属于“风险较低”的方案。它使用一致性约束和关键点引导注意力来增强表征能力, 因此兼顾了性能和可解释性。如果最终希望形成“一个最强模型 + 一个稳健高性能备选 + 一个经典基线”的组合, 那么 C2SLR 非常适合放在备选位。它特别适合在复现和对比实验中承担参照模型角色。

## ■ SignCLIP (EMNLP 2024)

论文: [SignCLIP](#)

代码: <https://github.com/J22Melody/fairseq/tree/main/examples/MMPT>

方向: 手语理解

**推荐理由:**

借鉴 CLIP 对比学习框架把手语和文本映射进同一语义空间, 训练完成后可直接做 zero-shot 检索/分类, 无需为每个任务单独微调。仓库 README 完整给出训练/评估流程, 并提供多个语言版本的预训练模型权重 (ASL/BSL/瑞士手语), 由论文一作维护、fork 自 Facebook 官方 fairseq, 可信度高。

**核心任务:**



负责 gloss-free 翻译与稳健识别备选模型复现；提供与 Uni-Sign 同路线的可对比方案，并探索 CLIP 对比学习 zero-shot 能力

#### 实施计划：

- 配置环境并完成数据预处理
- 复现模型并在 CSL\_Daily / Phoenix-2014(T) 上评估
- 记录 WER / BLEU-4 等指标并与组长基准对比
- 整理复现笔记与可运行代码，合并到主分支

### 🔗 方案四：谭燕琪（成员）

#### ■ A Simple Baseline（ECCV 2024）

论文：A Simple Baseline for Spoken Language to Sign Language Translation with 3D Avatars

代码：<https://github.com/FangyunWei/SLRT>

方向：手语生成(SLP)

#### 推荐理由：

现有系统的两个方向：①音频转手语 ②手语转文字；方向②已经用了 Uni-Sign（ICLR 2025，排名很高的方法），继续在这个方向“找更好的模型”边际收益有限——Uni-Sign 在 CSL-Daily 和 OpenASL 等数据集上已经是 SOTA 级别的结果。而方向①当前系统没有“文本到动作生成”的能力，只有几条固定动画。引入一个 Sign Language Production (SLP) 模型，把 lexicon 匹配替换成真实的动作生成，这是质变级的改进。同时其输出类型是 SMPL-X 3D 人体姿态参数序列 + 可渲染的 3D 虚拟人动画，和原模型的 UE5 数字人天然对接。同一篇论文也包含 text→sign 的翻译评估，可以和现有的 Uni-Sign 做对比实验。

#### ■ Sign-IDD（AAAI 2025）

论文：Sign-IDD: Iconicity Disentangled Diffusion for Sign Language Production

代码：<https://github.com/NaVi-start/Sign-IDD>

方向：手语生成

#### 推荐理由：

Sign-IDD 的核心创新：它提出了“手语标志性解纠缠”（Iconicity Disentanglement）的概念——手语中的一些手势是象形的（比如“吃”的手势模仿吃东西的动作），另一些是约定的（约定俗成的固定手势）。Sign-IDD 用一个扩散模型在生成过程中把这两类手势分离开来处理，生成效果更好。

## ■ SEDS (ACM MM 2024)

论文: [SEDS](#)

代码: <https://github.com/longtaojiang/SEDS>

方向: 手语检索

### 推荐理由:

做手语视频与文本的双向检索, 训练成本和数据需求远低于完整翻译模型, 评估指标清晰客观。仓库已发布预处理数据集和预训练模型下载, 复现门槛低, 且可作为“生成动作质量的自动化评估工具”接入项目。

### 核心任务:

负责手语生成(SLP)与检索方向模型复现; 为数字人补齐“文本/音频→手语动作”生成能力, 并引入自动评估工具

### 实施计划:

- 配置环境并完成数据预处理
- 复现模型并在 CSL\_Daily / Phoenix-2014(T) 上评估
- 记录 WER / BLEU-4 等指标并与组长基准对比
- 整理复现笔记与可运行代码, 合并到主分支

## 🔗 方案五: 郑松屹 (成员)

## ■ SOKE (Signs as Tokens) (ICCV 2025)

论文: Signs as Tokens: A Retrieval-Enhanced Multilingual Sign Language Generator

代码: <https://github.com/2000ZRL/SOKE>

方向: 手语生成

### 推荐理由:

①相比 Simple Baseline 的优势: Simple Baseline 的核心思路是“查词典+线性插值”——把文本翻译成 gloss, 再从词典里找出对应的 3D 姿态, 然后插值连接。SOKE 做的则是端到端的自回归生成: 训练一个解耦的 tokenizer 把 SMPL-X 姿态离散化成 token 序列 (身体/双手/面部各走一个分支), 再用 mBART 这个预训练语言模型来自回归预测动作 token 序列。整个流程不需要查词典, 是从文本直接生成完整动作。且 SOKE 支持三种手语——中国手语、德国手语和美国手语。②更高质量的动作生成: 多 head 解码——身体、左手、右手、面部是并行预测的, 不走扁平化序列; 检索增强——通过外部手语词典提供词级辅助信号, 生成的手语准确率更高; 推理效率更高 (多 token 同时预测)。但也有局限性, 即复现成本更高, 且与现有系统的适配路径匹配度较低。



## ■ Progressive Transformers (ECCV 2020)

论文: Progressive Transformers for End-to-End SLP

代码: <https://github.com/BenSaunders27/ProgressiveTransformersSLP>

方向: 手语生成(SLP)

### 推荐理由:

①输出的 3D 骨架序列 (每帧 150 维关节值) 可以映射到 UE5 骨骼, 驱动数字人; ②代码极完整——Configs/、Data/、\_\_main\_\_.py 训练入口、模型定义, 全都有; ③数据处理格式清晰, ProgressiveTransformersSLP 的数据格式已经是很多后来工作的基础格式; ④选一个 repo 实际上等于同时接触了 4 篇不同方向的论文 (Progressive Transformers / Mixed SIGNALs / Signing at Scale / Continuous 3D Multi-Channel SLP)。局限性: ①数据格式较老 (文本文件格式, 每行空格分隔), 需要一定的预处理工作; ②代码基于 PyTorch, 版本可能较老, 需要适配现代 PyTorch。

## ■ SignAvatar (IEEE FG 2024)

论文: [SignAvatar](#)

代码: <https://github.com/dongluddeeplearning/SignAvatar>

方向: 手语生成

### 推荐理由:

同时覆盖 3D 动作重建与生成两个任务, 输出直接面向数字人渲染的 3D 网格/骨骼参数, 工程链路上离“驱动虚拟人”更近。代码仓库训练、生成、评估脚本齐全。缺点: 数据集 ASL3DWord 需邮件向作者申请, 复现前要预留申请时间。

### 核心任务:

负责端到端手语生成与经典 SLP 基线复现; 探索自回归 token 生成与 3D 动作重建方案, 扩展数字人动作生成路径

### 实施计划:

- 配置环境并完成数据预处理
- 复现模型并在 CSL\_Daily / Phoenix-2014(T) 上评估
- 记录 WER / BLEU-4 等指标并与组长基准对比
- 整理复现笔记与可运行代码, 合并到主分支

## 四、进度计划

### 第 1 周：环境配置与数据准备

| 任务                          | 完成标准                         |
|-----------------------------|------------------------------|
| 配置统一的 <code>conda</code> 环境 | 所有成员可运行基础代码                  |
| 下载并预处理数据集                   | <code>CSL_Daily</code> 数据集可用 |
| 熟悉项目代码结构                    | 理解数据流向和模型架构                  |
| 确定模型方案细节                    | 每人明确自己的技术路线                  |

周汇报内容：环境搭建进度、数据集准备情况、模型方案确认

### 第 2、3、4 周：模型开发与初步训练

每人每周训练一个模型

| 任务                         | 完成标准                       |
|----------------------------|----------------------------|
| 搭建各自模型架构                   | 代码可运行，无语法错误                |
| 完成 <code>Stage1</code> 预训练 | 姿态/视觉编码器预训练完成              |
| 记录训练日志和指标                  | <code>Loss</code> 曲线、验证准确率 |

周汇报内容：模型架构设计、训练进度、遇到的问题

### 第 5 周：模型微调与优化

| 任务                          | 完成标准                                               |
|-----------------------------|----------------------------------------------------|
| 完成 <code>Stage3</code> 下游微调 | 在目标数据集上完成微调                                        |
| 进行模型评估                      | 在测试集上计算 <code>BLEU</code> / <code>BLEURT</code> 分数 |
| 尝试超参数调优                     | 学习率、 <code>batch_size</code> 等优化                   |

周汇报内容：当前模型性能、优化策略、改进方向

### 第 6 周：结果对比与总结

| 任务     | 完成标准          |
|--------|---------------|
| 统一评估指标 | 在相同测试集上进行公平对比 |
| 撰写实验报告 | 记录各模型的优缺点     |
| 确定最优方案 | 投票或根据指标选择最佳模型 |

周汇报内容：最终对比结果、最佳模型选择、项目总结

## 五、预期成果

1. 5 个独立模型方案：每个成员完成一个可运行的手语识别模型
2. 统一评估报告：包含各模型在相同数据集上的对比结果
3. 最佳模型选择：根据指标选出最优方案进行后续优化
4. 实时演示能力：最佳模型支持摄像头实时手语识别